

MÁSTER EN IA APLICADA A LA CIBERSEGURIDAD
MÓDULO 2. FUNDAMENTOS DE MACHINE LEARNING
TAREA 1 – LA REGRESIÓN LINEAL

MÁSTER EN INTELIGENCIA ARTIFICIAL APLICADA A LA CIBERSEGURIDAD



Campus Internacional
CIBERSEGURIDAD



UCAM
UNIVERSIDAD
CATÓLICA DE MURCIA

MÓDULO 2. FUNDAMENTOS DE MACHINE LEARNING	1
1. TAREA 1: la regresión lineal.	3
1.1 Comparación con Modelos de IA Avanzados:.....	3
1.2 Propuesta:	4
1.2.1 Configuración del Entorno	4
1.2.2 Dataset:.....	5
1.2.3 Entregables	7

1. TAREA 1: LA REGRESIÓN LINEAL.

La regresión lineal es un excelente punto de partida para introducir los conceptos fundamentales de la Inteligencia Artificial (IA) y el aprendizaje automático. Aunque es un modelo relativamente simple en comparación con las técnicas más avanzadas de IA, comparte muchos principios básicos con sus contrapartes más complejas.

1.1 Comparación con Modelos de IA Avanzados:

- **Número de Parámetros:** La regresión lineal típicamente tiene pocos parámetros (uno por variable independiente más el intercepto).
- **Los modelos de IA avanzados,** como las redes neuronales profundas, pueden tener millones de parámetros.
- **La regresión lineal es estrictamente lineal,** modelando relaciones directas entre variables. Los modelos de IA avanzados pueden capturar relaciones no lineales y altamente complejas.
- **Interpretabilidad:** La regresión lineal ofrece alta interpretabilidad; cada coeficiente tiene un significado claro. Los modelos de IA complejos a menudo funcionan como "cajas negras", siendo difíciles de interpretar.
- **Capacidad de Aprendizaje:** La regresión lineal aprende patrones lineales simples en los datos. Los modelos de IA avanzados pueden aprender patrones extremadamente complejos y abstractos.
- **Proceso de Entrenamiento:** La regresión lineal tiene una solución analítica directa (mínimos cuadrados). Los modelos de IA complejos requieren algoritmos de optimización iterativos y computacionalmente intensivos.

Entender la regresión lineal proporciona una base sólida para comprender conceptos más avanzados en IA, como el aprendizaje supervisado, las funciones de pérdida, la generalización, y los conceptos de sobreajuste y subajuste.

1.2 Propuesta:

A continuación, te presento un ejercicio sencillo de regresión lineal, ideal para que practiques los conceptos básicos y refuerces tu entendimiento de este tipo de modelo. La idea es que utilices el repositorio [Linear-Regression](#) como guía y punto de referencia para resolver la parte matemática.
el repositorio como guía y punto de referencia para resolverlo.

CONTEXTO:

Trabajas en el equipo de seguridad de una empresa que expone una API pública. Quieres construir un **primer prototipo muy simple** de motor de scoring que, dado un conjunto de características de una petición, calcule un **riesgo numérico** usando **regresión lineal**.

Este prototipo se expondrá como un **microservicio Flask**, sin base de datos ni colas ni nada avanzado: solo Python, Flask y un modelo en memoria.

1.2.1 Configuración del Entorno

1. Descarga o clona el repositorio [Linear-Regression](#) solo para entender cómo funciona.
2. Verifica que tienes instalado:
 - **Python 3** (recomendado 3.7+).
 - Bibliotecas necesarias: pandas, flask, numpy, matplotlib, scikit-learn.
(Si no las tienes, puedes instalarlas con pip `install nombre_de_la_biblioteca.`)

1.2.2 Dataset:

<https://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html>

*El **KDD Cup 1999** (KDD'99) es un dataset clásico para detección de intrusiones en red.*

- Se creó para la competición KDD Cup 1999, cuyo objetivo era construir un detector de intrusiones capaz de distinguir conexiones de red normales de conexiones maliciosas (ataques).
- Los datos vienen del programa DARPA 1998 de MIT Lincoln Lab: simularon durante varias semanas una red militar (LAN de la Fuerza Aérea de EE. UU.) con tráfico normal y muchos ataques inyectados, capturando todo con tcpdump y luego resumiendo cada flujo en un "registro de conexión".

En la práctica: cada fila del dataset = una conexión TCP/IP con sus características + etiqueta de ataque/normal.

Estructura básica del dataset:

Cada muestra tiene:

- 41 características (features).
- 1 etiqueta (tipo de conexión: normal o tipo de ataque).

El 10% set típico tiene 494 021 conexiones de entrenamiento y 311 029 de test, con fuerte desbalanceo entre clases (muchísimos DoS). Para nuestro caso no supone un problema.

El KDD Cup 1999 (KDD'99) es un dataset clásico para detección de intrusiones en red.

- Se creó para la competición KDD Cup 1999, cuyo objetivo era construir un detector de intrusiones capaz de distinguir conexiones de red normales de conexiones maliciosas (ataques).
- Los datos vienen del programa DARPA 1998 de MIT Lincoln Lab: simularon durante varias semanas una red militar (LAN de la Fuerza Aérea de EE.

UU.) con tráfico normal y muchos ataques inyectados, capturando todo con tcpdump y luego resumiendo cada flujo en un “registro de conexión”. En la práctica: cada fila del dataset = una conexión TCP/IP con sus características + etiqueta de ataque/normal.

Estructura básica del dataset:

Cada muestra tiene:

- 41 características (features).
- 1 etiqueta (tipo de conexión: normal o tipo de ataque).

OBJETIVO: SELECCIONAR LAS FEATURES QUE CONSIDERES Y ENTRENES UNA REGRESIÓN LINEAL QUE IMPLEMENTAR EN EL SERVIDOR.

LA CLASIFICACIÓN DEBE SER BINARIA (NORMAL, O CUALQUIER TIPO DE ATAQUE) PRE PROCESO PREVIO DE LOS DATOS ES NECESARIO.

Implementa un servicio en Flask que:

Entrena un modelo de regresión lineal a partir de un conjunto de datos que describe peticiones HTTP.

Expone un endpoint POST /score que recibe características de una petición y devuelve:

El score numérico predicho (riesgo).

Una decisión simple ("allow" / "flag") según un umbral configurable.

Expone un endpoint GET /model_info que devuelve:

Los coeficientes de la regresión.

El intercepto.

Una breve explicación de qué significa cada característica.

No se permite usar bases de datos: todo en memoria o ficheros planos (.csv, .pkl, etc.).

Consejo: Selecciona de las 41 features del dataset, las que consideres fáciles de extraer del dataset proporcionado.

avg bytes sent por ejemplo. Algo fácil de extraer de una request de las 41 opciones que tiene el dataset.

1.2.3 Entregables

- **Código fuente** en un archivo. Python vale, o cualquier otro lenguaje. Libertad total.
- **Explicación** de los pasos seguidos y las conclusiones que obtuviste tras entrenar el modelo. (PREPROCESO + ANALISIS)
- **Gráfica(s)** con la dispersión de puntos y la línea resultante del modelo.

¡Y eso es todo! Este ejercicio te servirá para:

- Familiarizarte con la carga, exploración y limpieza de datos.
- Aplicar el modelo de **Regresión Lineal**.
- Entender y evaluar el desempeño del modelo con métricas sencillas.

Puedes guiarte del repositorio [Linear-Regression](#) para ver ejemplos de implementación y otros detalles.

IMPORTANTE, NO HACE FALTA DESPLEGAR LA API EN NINGÚN SITIO. ME VALE CON LANZARLO EN LOCAL EN MODO DEBUG.